# ANALISIS CLUSTER

Made Satria Wibawa, M.Eng. 2020

## Outline

- Clustering
- Disimilaritas
- K-Means
- K-Medoid
- Evaluasi Cluster
- Implementasi

## **CLUSTERING**

## Clustering

Proses **pengelompokan** kumpulan dari objek data ke dalam beberapa **kelompok (cluster)** tertentu, dimana objek data dalam cluster yang sama memiliki tingkat kesamaan **(similaritas)** yang tinggi, namun sangat jauh berbeda dibandingkan dengan objek data/memiliki **disimilaritas** yang tinggi.

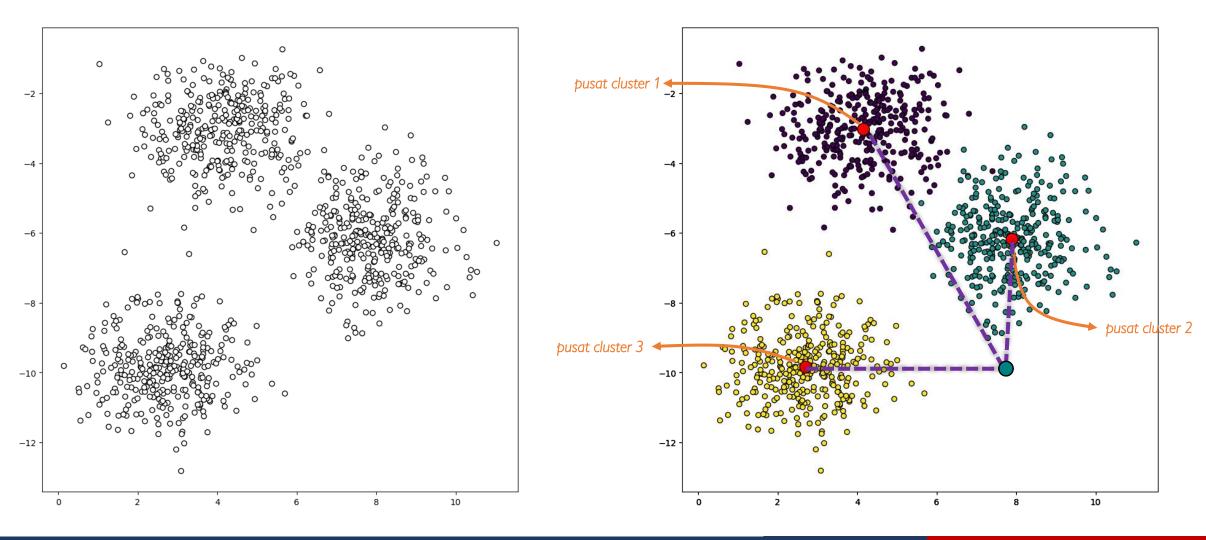
disimilaritas dihitung dari jarak antar nilai pada masing-masing atribut objek

### Penerapan:

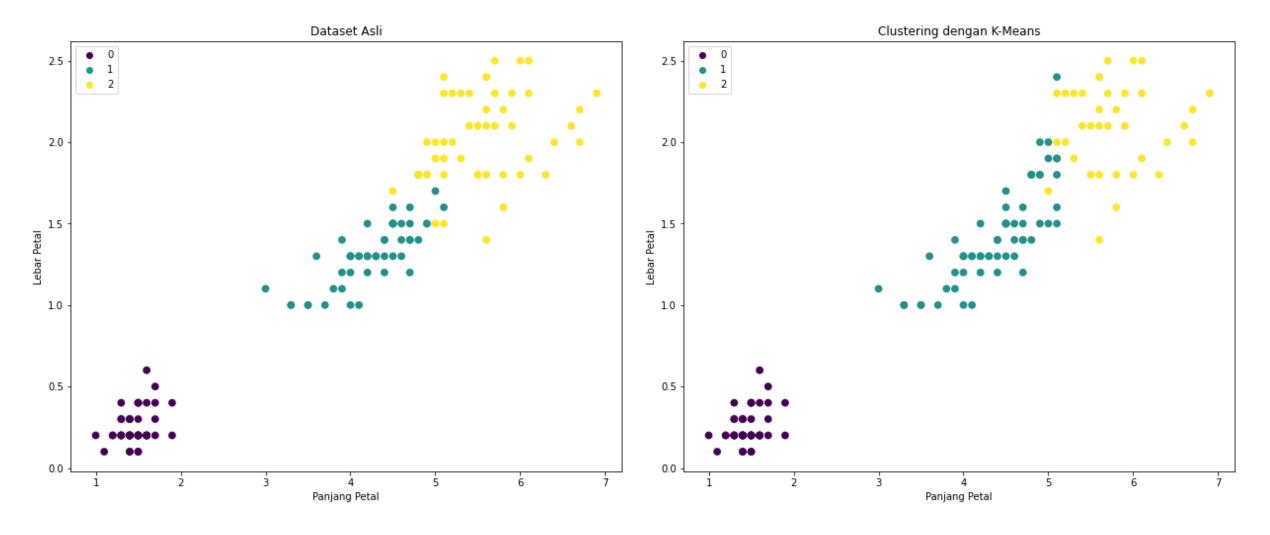
- Deteksi hoax
- Filter spam
- Marketing

- Deteksi aktivitas kriminal atau penipuan
- Analisis dokumen

# Clustering



## K-Means pada Dataset IRIS



## Metode Clustering

Partitioning

Metode ini membentuk data ke dalam partisi, dimana setiap partisi merepresentasikan cluster.

- K-means
- K-medoid
- Fuzzy c-means
- Density-based

Metode ini membentuk cluster dengan mempertimbangkan kerapatan (jumlah data) dalam area terdekat.

- DBSCAN
- Hierarchical

Metode ini membentuk cluster dalam bentuk

dekomposisi hirarki

- BIRCH
- CURE, OPTICS
- Grid-based

Metode ini membentuk cluster ke dalam bentuk struktur jaringan

Model-based

Metode cluster ini memperkenalkan probability cluster, tidak seperti k-means yang membentuk hard-cluster

- SOM
- EM algorithm

## DISIMILARITAS

### Disimilaritas

- Untuk banyak permasalahan, kita memerlukan kuantifikasi seberapa dekat antara dua buah objek.
- Disimilaritas adalah ketidakmiripan dari suatu objek. Kebalikannya adalah similaritas.
- Disimilaritas memiliki rentang nilai 0-1.
- 0 adalah sangat mirip, 1 adalah tidak mirip
- Contoh:
  - Segmentasi pasar
  - Pencarian dokumen digital
  - Pengecekan transaksi yang ganjil
- Untuk menyelesaikan permasalah ini kita memerlukan definisi disimilaritas atau distance
- Perhitungan similaritas akan berbeda untuk setiap tipe atribut

## Disimilaritas: Atribut Nominal

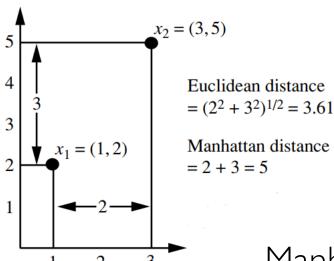
$$d(i,j) = \frac{p-m}{p}$$

- m adalah jumlah atribut yang memiliki nilai yang sama
- d(i,j) adalah distance/jarak antara objek i dan j
- p adalah jumlah keseluruhan atribut

Objek data	domisili	warna rambut	gender
А	Denpasar	Hitam	Pria
В	Gianyar	Hitam	Pria

$$d(A,B) = \frac{p-m}{p} = \frac{3-2}{3} = 0.33$$

## Disimilaritas: Atribut Numerik



Euclidean distance

$$d_{(a,b)} = \sqrt{\sum_{i=1}^{n} (a_i - b_i)^2}$$
$$= \sqrt{(a_1 - b_1)^2 + (a_2 - b_2)^2 + \dots + (a_n - b_n)^2}$$

Manhattan distance

$$d_{(a,b)} = \sum_{i=1}^{n} |a_i - b_i|$$

$$= |a_1 - b_1| + |a_2 - b_2| + \dots + |a_n - b_n|$$

## Disimilaritas: Atribut Numerik

Objek data	berat	tinggi	umur
Α	75	180	25
В	65	170	23

#### Euclidean distance

$$d_{(A,B)} = \sqrt{\sum_{i=1}^{n} (A_i - B_i)^2}$$

$$= \sqrt{(A_1 - B_1)^2 + (A_2 - B_2)^2 + (A_3 - B_3)^2}$$

$$= \sqrt{(75 - 65)^2 + (180 - 170)^2 + (25 - 23)^2}$$

$$= \sqrt{(10)^2 + (10)^2 + (2)^2}$$

$$= \sqrt{204} = 14.28$$

#### Manhattan distance

$$d_{(A,B)} = \sum_{i=1}^{n} |A_i - B_i|$$

$$= |A_1 - B_1| + |A_2 - B_2| + |A_3 - B_3|$$

$$= |75 - 65| + |180 - 170| + |25 - 23|$$

$$= |10| + |10| + |2| = 22$$

note: untuk atribut numerik, seharusnya kita melakukan normalisasi terlebih dahulu. namun, hanya sebagai contoh perhitungan, kita tidak akan melakukannya.

## K-MEANS

# Algoritma K-Means

### Algoritma:

K-Means

#### Input

k = jumlah cluster

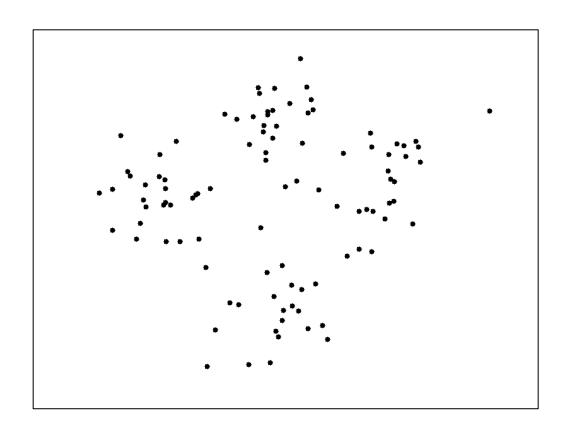
D = dataset yang memiliki n buah objek

#### Output

sekumpulan cluster

#### Metode

- 1) tentukan centroid sejumlah cluster
- 2) repeat
- 3) kelompokkan setiap objek ke centroid berdasarkan jarak terdekat
- 4) tentukan posisi centroid baru berdasarkan nilai rerata atribut setiap objek
- 5) until tidak ada perubahan keanggotaan



### Contoh: K-Means

Objek Data	X	у
A	1	2
В	2	3
С	4	3
D	5	4



#### Euclidean

$$k = 2$$

 $C_1 = (1,0)$ 

$$C_2 = (4,4)$$

$$d(_{A,C1}) = \sqrt{(1-1)^2 + (2-0)^2} = 2$$

$$d(_{A,C2}) = \sqrt{(1-4)^2 + (2-4)^2} = 3.6$$

$$d(_{B,C1}) = \sqrt{(2-1)^2 + (3-0)^2} = 3.2$$

$$d(_{B,C2}) = \sqrt{(2-4)^2 + (3-4)^2} = 2.2$$

$$d(_{C,C1}) = \sqrt{(4-1)^2 + (3-0)^2} = 4.2$$

$$d(_{C,C2}) = \sqrt{(4-4)^2 + (3-4)^2} = 1$$

$$d(_{D,C2}) = \sqrt{(5-1)^2 + (4-0)^2} = 5.7$$

$$d(_{D,C2}) = \sqrt{(5-4)^2 + (4-4)^2} = 1$$

Hitung jarak objek dengan centroid:

Objek Data	$dist ext{-}C_1$	dist-C <sub>2</sub>
A	2	3.6
В	3.2	2.2
С	4.2	1
D	5.7	1

#### Centroid baru

$$C_1 = \{A\}$$

$$x = 1$$

$$y = 2$$

$$C_2 = \{B, C, D\}$$

$$x = \frac{2+4+5}{3} = 3.6$$

$$y = \frac{3+3+4}{3} = 3.3$$

### Contoh: K-Means

Objek Data	X	у
A	1	2
В	2	3
С	4	3
D	5	4



k = 2

$$C_1 = (1,2)$$

$$C_2 = (3.6, 3.3)$$

#### Euclidean

Hitung jarak objek dengan centroid:

$$d(_{A,C1}) = \sqrt{(1-1)^2 + (2-2)^2} = 0$$

$$d(_{A,C2}) = \sqrt{(1-3.6)^2 + (2-3.3)^2} = 2.9$$

$$d(_{B,C1}) = \sqrt{(2-1)^2 + (3-2)^2} = 1.4$$

$$d(_{B,C2}) = \sqrt{(2-3.6)^2 + (3-3.3)^2} = 1.6$$

$$d(_{C,C1}) = \sqrt{(4-1)^2 + (3-2)^2} = 3.1$$

$$d(_{C,C2}) = \sqrt{(4-3.6)^2 + (3-3.3)^2} = 0.5$$

$$d(_{D,C1}) = \sqrt{(5-1)^2 + (4-2)^2} = 4.5$$

$$d(_{D,C2}) = \sqrt{(5-3.6)^2 + (4-3.3)^2} = 1.5$$

Objek Data	dist-C <sub>1</sub>	dist-C <sub>2</sub>
A	0	2.9
В	1.4	1.6
С	3.1	0.5
D	4.5	1.5

#### Centroid baru

$$C_1 = \{A, B\}$$
  
 $x = \frac{1+2}{2} = 1.5$ 

$$y = \frac{2+3}{2} = 2.5$$

$$C_2 = \{C, D\}$$
  
 $x = \frac{4+5}{2} = 4.5$ 

$$y = \frac{3+4}{2} = 3.5$$

### Contoh: K-Means

Objek Data	X	у
A	1	2
В	2	3
С	4	3
D	5	4



k = 2

Euclidean

 $C_1 = (1.5, 2.5)$ 

Hitung jarak objek dengan centroid:

$$C_2 = (4.5, 3.5)$$

$d(_{A,C1}) = \sqrt{(1-1.5)^2 + (2-2.5)^2}$	=	0.7
$d(A,C2) = \sqrt{(1-4.5)^2 + (2-3.5)^2}$	_	3.8
$d(_{B,C1}) = \sqrt{(2-1.5)^2 + (3-2.5)^2}$	=	0.7
$d(_{B,C2}) = \sqrt{(2-4.5)^2 + (3-3.5)^2}$	=	2.5
$d(_{C,C1}) = \sqrt{(4-1.5)^2 + (3-2.5)^2}$	_	2.5
$d(_{C,C2}) = \sqrt{(4-4.5)^2 + (3-3.5)^2}$	_	0.7
$d(D,C1) = \sqrt{(5-1.5)^2 + (4-2.5)^2}$	=	3.8
$d(D.C2) = \sqrt{(5-4.5)^2+(4-3.5)^2}$	=	0.7

Objek Data	$dist ext{-}C_1$	dist-C <sub>2</sub>
A	0.7	3.8
В	0.7	2.5
С	2.5	0.7
D	3.8	0.7

Tidak ada perubahan keanggotaan

### **FINISH**

## K-MEDOIDS

# Algoritma K-Medoids

### Algoritma:

PAM (Partitioning Around Medoids)

#### Input

k = jumlah cluster

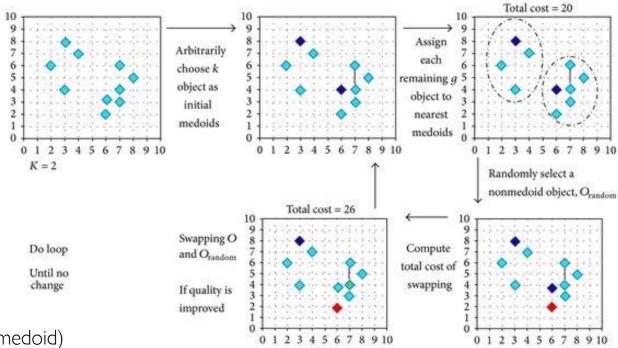
D = dataset yang memiliki n buah objek

#### Output

sekumpulan cluster

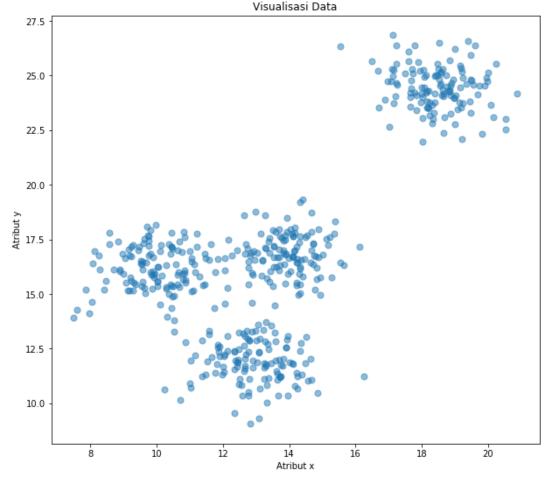
#### Metode

- 1) pilih secara acak k objek data dari D sebagai pusat cluster (medoid)
- 2) repeat
- 3) kelompokkan setiap objek ke medoid berdasarkan jarak terdekat
- 4) secara acak pilih objek selain medoid sebagai medoid baru, o<sub>random</sub>
- 5) hitung cost S, pergantian dari o<sub>i</sub> dengan o<sub>random</sub>
- 6) if S < 0 then tukar  $o_i$  dengan  $o_{random}$
- 7) until tidak ada perubahan keanggotaan



## **EVALUASI CLUSTER**

## Jumlah Cluster Terbaik



bagaimana cara menilai bahwa jumlah cluster yang digunakan adalah yang terbaik?

objek dalam satu cluster harus mirip, namun sangat berbeda dengan objek pada cluster yang lain

## Metode Silhoutte

### Metode Silhoutte

$$(1) \quad a(i) = \frac{1}{|C_i| - 1} \sum_{j \in C_i, i \neq j} d(i, j)$$

hitung jarak anggota dalam satu cluster

(2) 
$$b(i) = \min_{k \neq i} \frac{1}{|C_k|} \sum_{j \in C_k} d(i, j)$$

hitung jarak anggota dalam cluster yang berbeda

(3) 
$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

hitung silhouette score

$$s(i) = egin{cases} 1 - a(i)/b(i), & ext{if } a(i) < b(i) \ 0, & ext{if } a(i) = b(i) \ b(i)/a(i) - 1, & ext{if } a(i) > b(i) \end{cases}$$
  $-1 \le s(i) \le 1$ 

\*semakin tinggi nilai silhouette, maka posisi datum/objek dalam cluster semakin tepat

## Contoh Perhitungan Silhoutte Score

Objek Data	×	У
А	1	2
В	2	3
С	4	3
D	5	4

Hitung nilai silhouette objek A

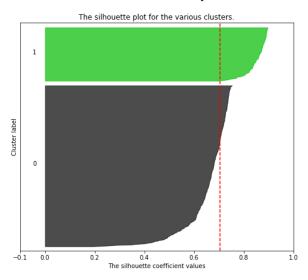
$$a_A = \frac{1}{2-1}d_{(A,B)} = \frac{1}{1}\left(\left(\sqrt{(1-2)^2 + (2-3)^2}\right)\right) = 1.4$$

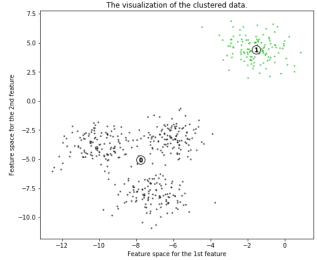
$$b_A = \frac{1}{2}(d_{(A,C)} + d_{(A,D)}) = \frac{1}{2}\left(\left(\sqrt{(1-4)^2 + (2-3)^2}\right) + \left(\sqrt{(1-5)^2 + (2-4)^2}\right)\right) = \frac{1}{2}(3.2 + 4.5) = 3.8$$

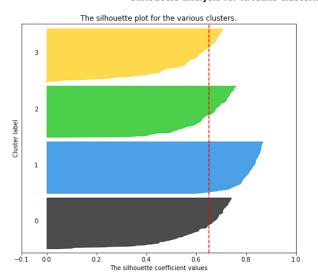
$$s_A = \frac{3.8 - 1.4}{\max(3.8, 1.4)} = \frac{2.4}{3.8} = 0.63$$

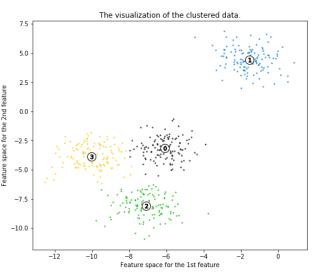
• Hitung nilai silhouette setiap objek, kemudian cari reratanya

#### Silhouette analysis for KMeans clustering on sample data with n\_clusters = 2

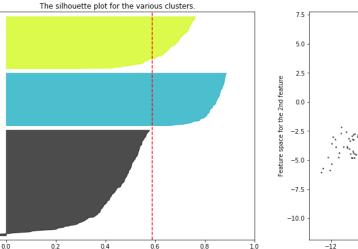


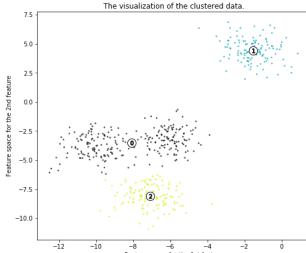


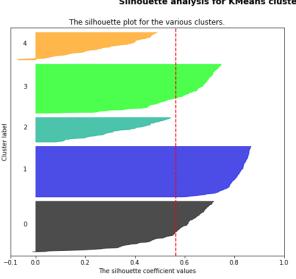


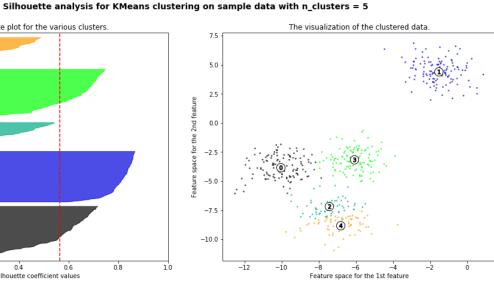


Silhouette analysis for KMeans clustering on sample data with n\_clusters = 3









Pertama: Nilai rata-rata harus sedekat mungkin dengan 1

The silhouette coefficient values

Kedua Plot masing-masing cluster harus di atas nilai ratarata sebanyak mungkin.

Ketiga Lebar plot harus seseragam mungkin.

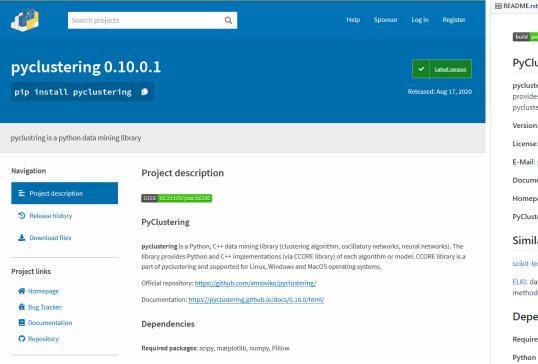
## **IMPLEMENTASI**

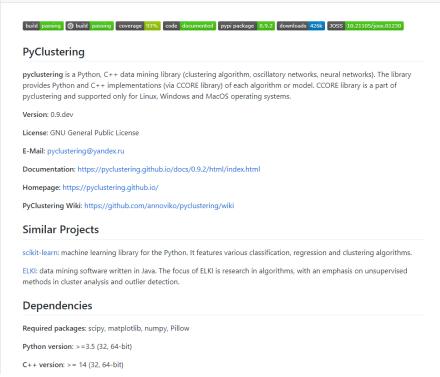
# Implementasi di Python

Untuk clustering, Anda dapat menggunakan library pyclustering

github: https://github.com/annoviko/pyclustering

pypi : https://pypi.org/project/pyclustering/





#### **Brief Overview of the Library Content**

Clustering algorithms and methods (module pyclustering.cluster):

Algorithm	Python	C++
Agglomerative	✓	✓
BANG	✓	
BIRCH	✓	
BSAS	✓	✓
CLARANS	✓	
CLIQUE	✓	✓
CURE	✓	✓
DBSCAN	✓	✓
Elbow	✓	✓
EMA	✓	
Fuzzy C-Means	✓	✓
GA (Genetic Algorithm)	✓	✓
G-Means	✓	✓
HSyncNet	✓	✓
K-Means	✓	✓
K-Means++	✓	✓
K-Medians	✓	✓
K-Medoids	✓	✓
MBSAS	<b>√</b>	✓
OPTICS	✓	✓
ROCK	✓	✓
Silhouette	✓	<b>√</b>
SOM-SC	<b>√</b>	<b>√</b>
SyncNet	<b>√</b>	✓
Sync-SOM	✓	
TTSAS	✓	✓
X-Means	✓	<b>√</b>

Always The First Made Satria Wibawa

## K-Means

```
In [1]:
         1 #import library
         2 from pyclustering.cluster.kmeans import kmeans
         3 from pyclustering.utils.metric import distance_metric, type_metric
In [2]:
         1 #Tentukan data
         2 data = [[1,2],[2,3],[4,3],[5,4]]
         3 print(data)
        [[1, 2], [2, 3], [4, 3], [5, 4]]
          1 #Tentukan centroid awal
In [3]:
         2 start_centroid = [[1,0],[4,4]]
         3 #Tentukan rumus distance
          4 metric = distance_metric(type_metric.EUCLIDEAN)
In [4]:
         1 #buat instance kmeans
         2 kmeans_ = kmeans(data, start_centroid, metric=metric)
         3 #jalankan kmeans
         4 kmeans_.process()
         5 #hitung cluster
         6 cluster_kmeans = kmeans__.get_clusters()
         7 #hitung centroid
         8 final_centroid = kmeans__.get_centers()
In [5]:
         1 print(cluster_kmeans)
         print(final_centroid)
        [[0, 1], [2, 3]]
        [[1.5, 2.5], [4.5, 3.5]]
```

## K-Medoids

```
In [1]: 1 from pyclustering.cluster.kmedoids import kmedoids
         2 from pyclustering.utils.metric import distance_metric, type_metric
         1 #Tentukan data
In [2]:
         2 data = [[1,2],[2,3],[4,3],[5,4]]
         3 print(data)
        [[1, 2], [2, 3], [4, 3], [5, 4]]
         1 #Tentukan medoid awal
In [3]:
         2 start medoid = [0,3]
         3 #Tentukan rumus distance
         4 metric = distance metric(type metric.EUCLIDEAN)
In [4]:
         1 #buat instance kmmedoids
         2 kmedoids = kmedoids(data, start medoid, metric=metric)
         3 #jalankan kmeans
         4 kmedoids .process()
         5 #hitung cluster
         6 cluster kmedoids = kmedoids .get clusters()
         7 #hitung centroid
         8 final medoids = kmedoids .get medoids()
         1 print(cluster_kmedoids)
In [5]:
         print(kmedoids__.get_medoids())
        [[0, 1], [3, 2]]
        [0, 3]
```



pertanyaan/troubleshooting silahkan buat di channel Diskusi Teams